УДК 519.872

Р.С. Хабаров
[степень, звание, место работы — заполнить]

ТОЧНАЯ ВЕРОЯТНОСТЬ НАРУШЕНИЯ SLA В МНОГОКАНАЛЬНЫХ СИСТЕМАХ ПАКЕТНОГО ОБСЛУЖИВАНИЯ С ОБЩЕЙ ОЧЕРЕДЬЮ: НЕТЕРПЕЛИВЫЕ ЗАЯВКИ

Рассмотрена система из n идентичных каналов пакетного (batch-service) обслуживания с общей очередью и пороговым запуском пакета — модель пула из нескольких реплик GPU-инференса за общим маршрутизатором запросов. Предложен точный метод вычисления вероятности нарушения SLA $P(W > D)$ для непрерывного времени, произвольных $n \geq 1$ и $1 \leq a \leq b$: при батч-размер-независимом обслуживании агрегированная ставка освобождения любого из n занятых каналов равна ровно $n\mu$ независимо от состава их занятости, что сводит ожидание помеченной заявки к уже решённой одноканальной конструкции с масштабированной ставкой. Метод распространён на марковское нетерпение заявок (та же агрегированная ставка переносит одноканальную конструкцию без изменений) и на батч-размер-*зависимое* обслуживание, для которого это упрощение перестаёт выполняться буквально: состав занятости каналов отслеживается внутри поглощающей цепи явно, но лишь пока заняты все n каналов, что удерживает пространство состояний заметно меньше первоначально ожидавшегося. Все результаты точно регрессируют к одноканальному случаю, к отсутствию нетерпения и к постоянному обслуживанию, и подтверждены независимым имитационным моделированием. Численно показано: добавление одной GPU-реплики в предельно нагруженный пул снижает среднее время ожидания более чем в 17 раз и вероятность нарушения дедлайна — более чем на порядок; нетерпение заявок и дополнительная ёмкость пула — взаимозаменяемые средства снижения ожидания, с убывающей отдачей от нетерпения по мере роста базовой ёмкости; а приближение зависящего от размера обслуживания одной постоянной ставкой систематически завышает и среднее время ожидания, и, заметно сильнее, вероятность нарушения дедлайна в хвосте.

Ключевые слова: теория массового обслуживания, пакетное обслуживание, многоканальные системы, общая очередь, SLA, вероятность нарушения дедлайна, нетерпеливые заявки, обслуживание, зависящее от размера пакета, инференс больших языковых моделей, динамический батчинг, пул GPU-реплик.

EXACT SLA-VIOLATION PROBABILITY FOR MULTI-SERVER THRESHOLD BATCH-SERVICE QUEUES WITH A SHARED QUEUE: CUSTOMER ABANDONMENT

R.S. Khabarov

We consider a pool of n identical batch-service servers sharing one queue with a threshold batch-formation rule — the natural model for a pool of GPU-inference replicas behind a

shared request router. We derive an exact deadline-violation probability $P(W > D)$ for continuous time, any $n \geq 1$ and $1 \leq a \leq b$: under batch-size-independent service, the aggregate rate at which any of the n busy servers next completes a batch is exactly $n\mu$ regardless of occupancy composition, which reduces the tagged customer's wait to the already-solved single-server construction with a rescaled rate. The method is extended to Markovian customer abandonment (the same aggregate rate carries the single-server construction over unchanged) and to batch-size-DEPENDENT service, for which this simplification no longer holds literally: occupancy composition is tracked explicitly inside the tagged customer's absorbing chain, but only while all n servers stay busy, which keeps the actual state space considerably smaller than initially expected. All results regress exactly to the single-server case, to no abandonment, and to constant service, and are validated against independent discrete-event simulation. Numerically: adding one GPU replica to a saturated pool cuts the mean wait by more than 17-fold and the deadline-violation probability by more than an order of magnitude; customer abandonment and extra capacity are substitutes for reducing wait, with diminishing returns from abandonment as baseline capacity grows; and approximating size-dependent service with a single constant rate systematically overstates both the mean wait and, considerably more so, the tail deadline-violation probability.

Key words: queueing theory, batch service, multi-server systems, shared queue, SLA, deadline-violation probability, customer abandonment, batch-size-dependent service, large language model inference, dynamic batching, GPU replica pool.

Введение

Ускорение инференса нейронных сетей на графических процессорах (GPU) существенно опирается на динамический батчинг — объединение нескольких независимо поступивших запросов в один пакет (batch), обрабатываемый каналом одновременно; такое объединение повышает пропускную способность канала ценой дополнительной задержки ожидания формирования и обслуживания пакета [1]. Операторы промышленных систем инференса, однако, почти никогда не ограничиваются одной GPU: типичное развёртывание — пул из нескольких идентичных реплик модели за общим маршрутизатором запросов, распределяющим нагрузку по общей очереди. Для таких пулов требование к качеству обслуживания формулируется в терминах вероятности, а не среднего: $P(\mathrm{TTFT} > D) < \varepsilon$ для времени до первого токена и заданного малого ε [2; 3], что делает точное (а не приближённое по среднему) распределение времени ожидания практически значимым и для многоканальной топологии.

Точное стационарное распределение длины очереди для систем пакетного обслуживания с зависящим от размера пакета временем обслуживания детально проработано, начиная с работы [4] и в серии последующих работ [5—8], но для одноканальной топологии; точное время ожидания помеченной заявки для общего (не обязательно зависящего от размера) обслуживания получено методом корней характеристического уравнения [9] — также только для одного канала. Автор этих строк ранее точно решил одноканальный случай с зависящим от размера пакета фазовым обслуживанием и его сочетание с нетерпением заявок [10]; настоящая работа распространяет точный результат на топологию с несколькими

параллельными каналами и общей очередью.

Несколько параллельных каналов батч-обслуживания изучались и ранее: недавняя работа [11] даёт точный анализ двух параллельных очередей с геометрическим батч-обслуживанием, но в дискретном времени и без общей очереди — каждая из двух очередей обслуживается своим каналом независимо, без разделения нагрузки между каналами. Это принципиальное отличие от рассматриваемой здесь топологии: общая очередь означает, что любой из n каналов может обслужить следующую по очереди заявку, и именно это разделение нагрузки определяет выигрыш от масштабирования числа каналов, количественно исследованный ниже. Нетерпение заявок в сочетании с несколькими каналами пакетного обслуживания и общей очередью ранее точно, по нашим сведениям, не рассматривалось.

Дальнейшая структура статьи следующая. Сначала приводится постановка задачи. Далее описан метод: конструкция для n идентичных каналов с общей очередью и её расширение на нетерпение заявок. После этого представлены численные эксперименты, количественно оценивающие эффект масштабирования числа каналов и его взаимодействие с нетерпением заявок.

Постановка задачи

Рассматривается система $M/M^{[a,b]}/n$: пуассоновский входной поток интенсивности λ; $n \geq 1$ идентичных каналов обслуживают пакеты заявок из одной общей очереди; каждый освободившийся канал начинает обслуживание пакета, как только накопится не менее a ожидающих заявок, и забирает в пакет $\min(b, j)$ заявок, где j — число ожидающих в момент запуска ($1 \leq a \leq b$ — общий порог запуска). Время обслуживания пакета размера s — экспоненциальное с темпом $\mu(s)$, одинаковым для всех n каналов; базовый случай — постоянная ставка $\mu(s) \equiv \mu$, не зависящая от размера пакета.

Базовая цель — точное $P(W > D)$ для $D \geq 0$, где W — время ожидания в очереди случайно выбранной (по PASTA) заявки, при любом $n \geq 1$ и любом $1 \leq a \leq b$, при батч-размер-независимом обслуживании. Эта конструкция расширяется в двух направлениях. Во-первых, на нетерпение заявок: каждая из j ожидающих заявок независимо покидает очередь с постоянной ставкой γ (марковское/беспамятное терпение, конвенция модели Erlang-A [12]), если её обслуживание не началось; цель — точная вероятность того, что помеченная заявка покинет очередь до начала своего пакета, и точное условное (на «дождалась») распределение W. Во-вторых, на батч-размер-*зависимое* обслуживание $\mu(s)$, произвольную функцию размера пакета; цель — то же точное $P(W > D)$, но уже без батч-размер-независимого упрощения, на котором держится базовая конструкция. Оба расширения получены раздельно (их сочетание — нетерпение при batch-size-зависимом обслуживании — остаётся резервом, см. раздел «Ограничения»).

Метод

Базовая конструкция, n идентичных каналов. Состояние системы — вектор занятости $(m_1, \ldots, m_b)$ (число каналов, занятых пакетом размера s, $s = 1, \ldots, b$; $n - \sum m_s$ — число свободных каналов), скрещенный с числом ожидающих заявок j. Пакет при хотя бы одном свободном канале запускается немедленно по достижении порога a (той же конвенцией, что и в одноканальном случае [10]) — отсюда встроенный инвариант: свободный канал есть $\Rightarrow j < a$ (иначе он уже забрал бы заявки). Стационарное распределение находится прямым решением $\pi Q = 0$ для разреженного генератора Q этой цепи Маркова.

Ключевое упрощение, не предполагавшееся заранее, — для батч-размер-независимого μ агрегированная ставка «следующее освобождение» среди всех занятых каналов равна ровно (число занятых каналов)$\cdot\mu$ независимо от состава их занятости (по беспамятности экспоненциального обслуживания и немедленному повторному запуску освободившегося канала, если накопленных заявок достаточно). В частности, когда заняты все n каналов, эта ставка равна ровно $n\mu$. Время ожидания помеченной заявки при всех занятых каналах поэтому не требует отслеживания вектора занятости вовсе: число заявок впереди помеченной убывает на b при каждом событии освобождения со ставкой $n\mu$ — в точности одноканальная конструкция [10] с единой ставкой $n\mu$ на всём протяжении вместо исходной ставки μ (и без различия «первый пакет vs последующие», поскольку здесь нет понятия «застигнутый пакет»: любой из n одинаковых каналов может освободиться следующим). Если хотя бы один канал свободен, $W = 0$ (помеченная заявка сразу попадает в пакет на свободном канале) либо время ожидания сводится к ожиданию накопления недостающих заявок по пуассоновскому потоку – та же конструкция, что и в одноканальном случае.

Расширение: нетерпение заявок. Каждая из j ожидающих заявок покидает очередь со ставкой γ. Благодаря тому же упрощению агрегированной ставки, одноканальная конструкция нетерпения [10] — явный конечный подгенератор T поглощающей цепи Маркова на состоянии (R, K) (R — число выживших впереди помеченной заявки, K — новые приходы позади неё), с конкурирующими поглощающими типами «обслужена» (ставка освобождения канала) и «ушла по терпению» (ставка γ, пропорциональная числу выживших впереди), — переносится без каких-либо изменений в самой структуре состояния: единственное отличие — подстановка ставки обслуживания $n\mu$ вместо μ там, где конструкция для одного канала использует ставку освобождения занятого канала. Формулы вероятности ухода и условных моментов времени ожидания — те же, что и в одноканальном случае:

$$P(\text{уход}) = \gamma\,\alpha\,(-T)^{-1}\mathbf{1}, \qquad \mathrm{E}[W^k;\,\text{обслужена}] = k!\,\alpha\,(-T)^{-(k+1)}\,r, \tag{1}$$

нормированные на $P(\text{обслужена}) = 1 - P(\text{уход})$ для получения условных моментов; r — вектор ставок обслуживания, здесь равный $n\mu$ в каждой компоненте, отвечающей состоянию, где формируется пакет, включающий помеченную заявку.

Регрессионные тождества — по $n = 1$ (точное совпадение с одноканальной конструкцией [10], включая случай $\gamma > 0$) и по $\gamma = 0$ (точное совпадение

с конструкцией без нетерпения) — выполняются точно. Независимая проверка имитационным моделированием (пул из n каналов с общей очередью, каждая ожидающая заявка независимо покидает очередь со ставкой γ; время ожидания измерено как момент начала обслуживания минус момент прихода, а не момент завершения пакета) подтверждает точность конструкции на нескольких комбинациях (a, b, n) и значений γ, в том числе по вероятности ухода и условному среднему времени ожидания.

Расширение: батч-размер-зависимое обслуживание. Если темп $\mu(s)$ зависит от размера пакета s, ключевое упрощение базовой конструкции перестаёт выполняться буквально: агрегированная ставка «следующее освобождение» среди занятых каналов равна $\sum_s n_s\,\mu(s)$, где n_s — число каналов, занятых пакетом размера s, — и генуинно зависит от состава занятости $(n_1, \ldots, n_b)$, а не только от их числа. Поглощающая цепь помеченной заявки поэтому несёт состав занятости как явную часть состояния: $(\text{состав}, R, K)$, где R и K — те же величины, что и в расширении на нетерпение. Каждый занятый класс размера s (с $n_s > 0$) вносит собственную конкурирующую ставку $n_s\,\mu(s)$; при срабатывании — если накопленного $R + 1 + K$ всё ещё достаточно для немедленного повторного запуска ($\geq a$) и это не включает помеченную заявку — состав предсказуемо обновляется ($n_s \mathrel{-}= 1$, $n_{\min(b,R+1+K)} \mathrel{+}= 1$, поскольку освободившийся канал немедленно забирает новый пакет), и цепь продолжается с уменьшенным R.

Ключевая находка, не предполагавшаяся заранее и заметно сужающая ожидавшийся взрыв размерности состояния, — состав занятости нужно отслеживать *только* пока заняты все n каналов. В момент, когда освободившийся канал не может сразу забрать новый пакет (накопленного $R + 1 + K$ всё ещё меньше a), он простаивает — и с этого момента дальнейшие завершения остальных ещё занятых каналов уже не способны изменить содержимое очереди (канал, завершающий обслуживание при неизменном числе ожидающих, лишь создаёт ещё один простаивающий канал, а не диспетчеризацию). Поэтому с этого момента действует уже существующая, не зависящая от состава занятости гонка ожидания накопления по пуассоновскому потоку — та же конструкция, что и в расширении на нетерпение (при $\gamma = 0$). Это ограничивает отслеживаемое пространство составов занятости только векторами с суммой ровно n (а не $\leq n$, как для полного стационарного распределения) — заметно меньшее множество, не зависящее от усечения очереди.

На рисунке 1 приведён пример эволюции состава занятости для $n = 2$ каналов, $b = 2$ (темпы $\mu(1)$, $\mu(2)$), показывающий только переходы, сохраняющие оба канала занятыми (случай «ещё достаточно впереди»; выходы в «обслужена» и «простой» зависят от R, а не от состава, и здесь не изображены — та же логика, что и для поглощения в расширении на нетерпение).

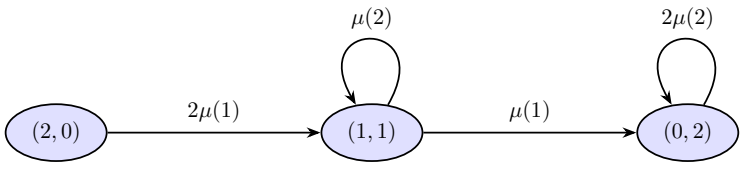


Рисунок 1. Эволюция состава занятости (n_1, n_2) для $n = 2$ каналов, $b = 2$ (только переходы, сохраняющие оба канала занятыми); узел — число каналов, занятых пакетом размера 1 и размера 2 соответственно

Регрессионное тождество — по постоянному $\mu(s) \equiv \mu$ (точное, до полной точности float64, совпадение с базовой конструкцией) — выполняется точно. Независимая проверка имитационным моделированием на генуинно батч-размер-зависимом $\mu(s) = 1/(0{,}3 + 0{,}25s)$ (таблица 1) подтверждает точность конструкции по среднему времени ожидания и хвосту $P(W > t)$.

Таблица 1. Расчёт и имитация: batch-size-зависимое обслуживание ($2{,}5 \times 10^6$ заявок на прогон)

(a, b, n, λ)	E$[W]$			$P(W > 1)$		
	теор.	ИМ	отн. ошибка	теор.	ИМ	отн. ошибка
$(2, 4, 2, 1{,}0)$	0,5072	0,5063	0,18 %	0,1861	0,1860	0,04 %
$(2, 3, 2, 1{,}3)$	0,4013	0,4006	0,18 %	0,1416	0,1414	0,16 %

Расхождение не превышает 0,18 % по среднему времени ожидания и 0,16 % по хвосту — в пределах статистической погрешности, ожидаемой при таком объёме испытаний.

Численные эксперименты

Эффект числа каналов. На параметрах batch-size-зависимости среднего [1] ($\alpha = 0{,}1438$, $\tau_0 = 1{,}8874$), с батч-размер-независимым экспоненциальным обслуживанием со средним, равным среднему при размере пакета 4 ($\mu = 1/(4\alpha + \tau_0) \approx 0{,}4061$ — максимальная пропускная способность одного канала при $b_{\max} = 4$ составляет $4\mu \approx 1{,}624$), $a = 2$, $b_{\max} = 4$, общая интенсивность входного потока $\lambda = 1{,}5$ (97,5 % от максимальной пропускной способности одного канала — система с $n = 1$ стабильна, но предельно нагружена), таблица 2 показывает эффект добавления идентичных каналов в общий пул с общей очередью.

Таблица 2. Эффект числа каналов n при фиксированной суммарной нагрузке ($\lambda = 1{,}5$, $\gamma = 0$)

n	E$[W]$	$P(W > 5)$	$P(W > 10)$	Загрузка канала
1	19,754	0,7633	$5{,}97 \times 10^{-1}$	0,975
2	1,144	$2{,}95 \times 10^{-2}$	$1{,}45 \times 10^{-3}$	0,739
3	0,509	$1{,}47 \times 10^{-3}$	$5{,}63 \times 10^{-6}$	0,574
4	0,370	$3{,}15 \times 10^{-4}$	$1{,}71 \times 10^{-7}$	0,454

Переход от одного предельно нагруженного канала к двум ($n = 1 \to 2$) снижает E$[W]$ более чем в 17 раз и $P(W > 5)$ — более чем в 25 раз, хотя суммарная входная нагрузка не изменилась: с одним каналом система работает на грани устойчивости ($\rho = 97{,}5$ %), и каждая дополнительная GPU-реплика пула не просто делит нагрузку поровну, а снимает именно ту часть перегрузки, которая отвечает

за формирование длинного хвоста ожидания. При дальнейшем увеличении n отдача убывает (переход $n = 2 \to 3$ даёт более чем 20-кратное улучшение $P(W > 5)$, а переход $n = 3 \to 4$ — «лишь» примерно 4,7-кратное) — типичная для систем массового обслуживания картина убывающей отдачи от масштабирования числа каналов, здесь впервые точно, а не оценочно, количественно определённая для системы пакетного обслуживания с общей очередью. Практический вывод для оператора GPU-пула: при близкой к насыщению нагрузке одна дополнительная реплика значительно ценнее, чем может показаться по простому «делению нагрузки на n».

Взаимодействие нетерпения заявок с числом каналов. На тех же параметрах (таблица 3) показан эффект ставки терпения γ при трёх разных n — вероятность отмены запроса до начала его пакета $P(\text{уход})$, условное (на «дождался») среднее время ожидания $\mathrm{E}[W \mid \text{обслужена}]$ и истинная вероятность выполнения SLA с дедлайном $D = 10$ — $P(\text{обслужена и } W \le D)$.

Таблица 3. Нетерпение заявок при разном числе каналов ($D = 10$)

n	γ	$P(\text{уход})$	$\mathrm{E}[W \mid \text{обслужена}]$	$P(\text{обслужена и } W \le D)$
1	0	0	19,93	0,4022
1	0,1	0,2496	2,51	0,7388
1	0,3	0,4011	1,27	0,5984
2	0	0	1,14	0,9985
2	0,1	0,0864	0,84	0,9135
2	0,3	0,1914	0,59	0,8086
3	0	0	0,509	0,99999
3	0,1	0,0459	0,446	0,95410
3	0,3	0,1185	0,365	0,88148

Таблица 3 вскрывает качественно различную картину в зависимости от n. При $n = 1$ (предельно нагруженный одиночный канал, $\rho = 97{,}5\,\%$) нетерпение заявок — не только статистический артефакт, но и ощутимый практический рычаг: оно само по себе действует как предохранительный клапан, отсекающий избыточную нагрузку и поднимающий истинную вероятность выполнения SLA с 40,2 % ($\gamma = 0$, система фактически не справляется с нагрузкой на горизонте $D = 10$) до 73,9 % уже при скромной ставке $\gamma = 0{,}1$ — рост, целиком проистекающий из статистического отбрасывания части нагрузки, а не из улучшения самой системы; при дальнейшем росте γ выигрыш не монотонен (при $\gamma = 0{,}3$ показатель снижается до 59,8 %), поскольку увеличивающаяся доля уходов в конце концов начинает учитываться как провал SLA наравне с нарушением дедлайна. При $n = 3$ (загрузка канала уже умеренная, 57,4 %) та же ставка терпения $\gamma = 0{,}3$ отсекает заметно меньшую долю нагрузки (11,85 % против 40,1 % при $n = 1$) и из уже близкой к единице вероятности SLA-успеха без нетерпения (99,999 %) снижает её до 88,15 % — то есть при низкой базовой загрузке нетерпение заявок способно только ухудшить наблюдаемый SLA-показатель, отбрасывая заявки, которые и так были бы обслужены в срок.

Это — количественное проявление взаимозаменяемости двух средств снижения времени ожидания, упомянутой во введении: нетерпение заявок компенсирует недостаток ёмкости пула, но ценой прямой потери части нагрузки, тогда как дополнительная ёмкость устраняет саму причину долгого ожидания без этой потери. Для оператора, управляющего пулом GPU-реплик, вывод прямой: наблюдаемое улучшение SLA-метрик при увеличении ставки нетерпения (или при агрессивных клиентских таймаутах, эквивалентных росту γ) не свидетельствует об улучшении системы и не должно восприниматься как альтернатива добавлению ёмкости при хронической перегрузке пула.

Цена приближения постоянным обслуживанием. Таблица 2 выше вычислена при единственной ставке $\mu = 1/(4\alpha + \tau_0)$ — приближении, соответствующем размеру пакета $b_{\max} = 4$, то есть предположению, что каждый пакет полноразмерный. На тех же параметрах, но с истинным батч-размер-зависимым $\mu(s) = 1/(\alpha s + \tau_0)$ (та же подгонка по среднему, что и всюду в статье), таблица 4 сравнивает точный результат с этим приближением при $\gamma = 0$.

Таблица 4. Точное батч-размер-зависимое обслуживание против приближения постоянной ставкой $\mu(b_{\max})$

n	Точное E$[W]$	Приближение	Точное $P(W > 10)$	Приближение
2	0,964	1,144	$8{,}04 \times 10^{-4}$	$1{,}45 \times 10^{-3}$
3	0,448	0,509	$1{,}45 \times 10^{-6}$	$5{,}63 \times 10^{-6}$

Приближение постоянной ставкой систематически *завышает* и среднее время ожидания (на 18,7 % при $n = 2$, на 13,6 % при $n = 3$), и, заметно сильнее, вероятность нарушения дедлайна в хвосте (на 80 % при $n = 2$, почти в 4 раза при $n = 3$) — направление ошибки объясняется тем, что реальные пакеты зачастую меньше $b_{\max}$ (особенно вблизи порога a), а при убывающей по размеру ставке $\mu(s) = 1/(\alpha s + \tau_0)$ меньшие пакеты обслуживаются быстрее: подстановка темпа самого медленного (полноразмерного) пакета вместо истинного смешанного темпа делает пул искусственно более перегруженным, чем он есть на самом деле. Эффект усиливается с глубиной хвоста — та же качественная картина, что и для однополюсного приближения хвоста в [10]: грубое приближение одной ставкой терпимо для среднего, но ненадёжно именно там, где нужна точность SLA-ориентированного управления.

Ограничения

Батч-размер-зависимое обслуживание и нетерпение заявок реализованы раздельно; их сочетание остаётся резервом — поглощающая цепь состава занятости (раздел «Метод») не несёт переходов по уходу заявок впереди, перенос которых потребовал бы их добавления к уже и так расширенному состоянию. Фазовое (Erlang/H_2) обслуживание при $n > 1$ также оставлено резервом: оно добавило бы фазовое измерение к каждому занятому каналу поверх уже отслеживаемого состава занятости. Нетерпение заявок для H_2-обслуживания даже в одноканальном случае — отдельный резерв, рассмотренный в [10], не затрагиваемый здесь.

Численные примеры (таблицы 2–4) — иллюстративные, на одном наборе параметров ($a = 2$, $b_{\max} = 4$, фиксированная суммарная нагрузка) каждый; систематическое исследование по сетке параметров (аналогичное исследованию порога a и $b_{\max}$ в [10]) для многоканальной топологии не проводилось. В частности, наблюдение о немонотонности эффекта нетерпения по n (ощутимая польза при высокой загрузке, чистый вред при низкой) — качественный вывод на конкретных параметрах, а не доказанное в общем виде свойство; то же относится к направлению и величине ошибки приближения постоянным обслуживанием (таблица 4), проверенного только для одной убывающей по размеру функции $\mu(s)$.

Заключение

Получена и верифицирована точная вероятность нарушения SLA для системы пакетного обслуживания из n идентичных каналов с общей очередью и общим порогом запуска пакета $1 \leq a \leq b$, при батч-размер-независимом времени обслуживания, — результат, основанный на точном показе того, что агрегированная ставка освобождения любого из занятых каналов не зависит от состава их занятости, что сводит многоканальную конструкцию к уже решённой одноканальной [10] с масштабированной ставкой. Метод распространён на марковское нетерпение заявок, для которого та же агрегированная ставка позволяет перенести одноканальную конструкцию нетерпения без изменения её структуры, и на батч-размер-зависимое обслуживание, для которого это упрощение перестаёт выполняться буквально и состав занятости каналов приходится отслеживать явно внутри поглощающей цепи помеченной заявки — но, как показано, только пока все каналы заняты, что удерживает фактическое пространство состояний заметно меньше того, что предполагал первоначальный анализ риска.

Численно показано, что добавление одной GPU-реплики в предельно нагруженный пул снижает среднее время ожидания более чем в 17 раз, а вероятность нарушения дедлайна — более чем на порядок, с типичной для масштабирования числа каналов убывающей отдачей; что нетерпение заявок и дополнительная ёмкость пула действуют как в существенной мере взаимозаменяемые средства: та же ставка терпения резко повышает истинную вероятность выполнения SLA при высокой базовой загрузке пула, но при умеренной загрузке лишь отбрасывает часть нагрузки, которая и так была бы обслужена в срок, ухудшая наблюдаемый показатель; и что приближение батч-размер-зависимого обслуживания одной постоянной ставкой, откалиброванной по самому крупному размеру пакета, систематически завышает среднее время ожидания на 14–19 % и вероятность нарушения дедлайна в хвосте — в разы. Эти результаты прямо предостерегают от использования клиентских таймаутов как замены достаточной ёмкости инференс-пула и от грубого приближения обслуживания одной ставкой там, где нужна точность SLA-ориентированного управления. Открытая программная реализация всех описанных методов доступна в библиотеке most-queue [13].

Список литературы

1. *Inoue Y.* Queueing analysis of GPU-based inference servers with dynamic batching: a closed-form characterization // Performance Evaluation. — 2021. — T. 147.
2. QUARTZ: Quantile-Aware Routing and Queueing for TTFT SLOs in LLM Serving / Z. Liu [и др.] // Findings of the Association for Computational Linguistics: ACL 2026. — 2026. — С. 37886—37896. — DOI: 10.18653/v1/2026.findings-acl.1888.
3. JITServe: SLO-aware LLM Serving with Imprecise Request Information / W. Zhang [и др.] // Proceedings of the 23rd USENIX Symposium on Networked Systems Design and Implementation (NSDI 2026). — 2026. — arXiv: 2504.20068.
4. *Banerjee A.*, *Gupta U. C.* Reducing congestion in bulk-service finite-buffer queueing system using batch-size-dependent service // Performance Evaluation. — 2012. — Т. 69, № 1. — С. 53—70.
5. *Pradhan S.*, *Gupta U. C.*, *Samanta S. K.* Queue-length distribution of a batch service queue with random capacity and batch size dependent service: $M/G^{Y}_{r}/1$ // OPSEARCH. — 2016. — Т. 53. — С. 329—343. — DOI: 10.1007/s12597-015-0231-8.
6. *Banerjee A.*, *Gupta U. C.*, *Chakravarthy S. R.* Analysis of a finite-buffer bulk-service queue under Markovian arrival process with batch-size-dependent service // Computers & Operations Research. — 2015. — Т. 60. — С. 138—149. — DOI: 10.1016/j.cor.2015.02.012.
7. *Gupta G. K.*, *Banerjee A.* On $M/G^{(a,b)}/1/N$ queue with batch size- and queue length-dependent service // Mathematics and Computing (ICMC 2018). Т. 253. — Singapore : Springer, 2018. — С. 249—262. — (Springer Proceedings in Mathematics & Statistics). — DOI: 10.1007/978-981-13-2095-8_20.
8. *Pradhan S.*, *Nandy N.*, *Gupta U. C.* Performance analysis of a versatile bulk-service queue with group-arrival, batch-size-dependent service time and queue-length-dependent vacation // Quality Technology & Quantitative Management. — 2024. — Т. 22, № 4. — С. 683—726. — DOI: 10.1080/16843703.2024.2391673.
9. A Novel Computational Procedure for the Waiting-Time Distribution (In the Queue) for Bulk-Service Finite-Buffer Queues with Poisson Input / M. L. Chaudhry [и др.] // Mathematics. — 2023. — Т. 11, № 5. — DOI: 10.3390/math11051142.
10. *Хабаров Р. С.* Точная вероятность нарушения SLA в одноканальных системах пакетного обслуживания с пороговым запуском пакета: нетерпеливые заявки. — 2026. — рукопись в подготовке.
11. *Bruneel H.* Two parallel queues with geometric batch servers // Queueing Systems. — 2026. — Т. 110, № 1. — DOI: 10.1007/s11134-026-09970-9.

12. *Garnett O.*, *Mandelbaum A.*, *Reiman M.* Designing a Call Center with Impatient Customers // Manufacturing & Service Operations Management. — 2002. — Т. 4, № 3. — С. 208—227. — DOI: 10.1287/msom.4.3.208.7753.

13. *Хабаров Р. С.* most-queue: библиотека точных и приближённых методов теории очередей. — 2026. — URL: https://github.com/xabarov/most-queue (дата обр. 06.10.2026).