УДК 519.872

Р.С. Хабаров, к.т.н.

ТОЧНОЕ РАСПРЕДЕЛЕНИЕ ВРЕМЕНИ ОЖИДАНИЯ В СИСТЕМЕ МАССОВОГО ОБСЛУЖИВАНИЯ С OCCUPANCY-ЗАВИСИМОЙ ИНТЕНСИВНОСТЬЮ И ПОТОЛКОМ ЗАНЯТОСТИ

Рассмотрена одноканальная (в смысле общего разделяемого ресурса) система массового обслуживания, в которой до k заявок обслуживаются одновременно, интенсивность обслуживания каждой заявки зависит от текущего числа одновременно обслуживаемых (occupancy-зависимая интенсивность обслуживания), а превышающие потолок k заявки ожидают по дисциплине FCFS. Такая система – точная марковская модель ядра «continuous batching» (непрерывного, поитерационного формирования батча) современных движков инференса больших языковых моделей (LLM), где k задаётся объёмом доступной памяти ускорителя (KV-cache), а occupancy-зависимость интенсивности обслуживания отражает разделяемую вычислительную мощность/пропускную способность памяти между одновременно обслуживаемыми запросами. Показано, что стационарное распределение числа заявок в системе имеет точную (не итеративную) мультипликативную форму в силу детального баланса, присущего любому процессу гибели-размножения; показано также, что занятость канала жёстко зафиксирована на уровне k в любом состоянии с непустой очередью, откуда следует точное представление времени ожидания PASTA-наблюдающей заявки в виде явной смеси эрланговских распределений – точные начальные моменты и точный хвост $P(W > D)$, а не только среднее значение, как в единственной найденной близкой по постановке работе. Результат точно регрессирует к классической системе $M/M/k/N$ при occupancy-независимой интенсивности и к $M/M/1/N$ при $k = 1$; подтверждён независимым имитационным моделированием. Численно показано, что простое приближение, игнорирующее occupancy-зависимость интенсивности (использующее интенсивность, измеренную при полной занятости, как константу), систематически завышает вероятность нарушения дедлайна – на один-два порядка при умеренной занятости и на несколько порядков при большом потолке занятости k.

Ключевые слова: теория массового обслуживания, occupancy-зависимое обслуживание, процесс гибели-размножения, потолок занятости, continuous batching, инференс больших языковых моделей, KV-cache, точное распределение времени ожидания.

EXACT WAITING-TIME DISTRIBUTION FOR AN OCCUPANCY-DEPENDENT QUEUE WITH A CONCURRENCY CAP: THE MARKOVIAN CORE OF LLM-SERVING CONTINUOUS BATCHING

R.S. Khabarov

We consider a single shared-resource queueing system in which up to k customers are served concurrently, the per-customer completion rate depends on the current number of

concurrently-served customers (an occupancy-dependent rate), and customers beyond the cap k wait FCFS. This system is an exact Markovian model of the core mechanism of "continuous batching" in modern large language model (LLM) inference engines, where k is set by available accelerator memory (the KV-cache) and the occupancy-dependent rate reflects shared compute/memory-bandwidth capacity among concurrently-resident requests. We show that the stationary distribution of the number in system has an exact (non-iterative) product form, a consequence of detailed balance for any birth-death process; we further show that occupancy is pinned at exactly k in every state with a nonempty queue, from which an exact representation of the waiting time of a PASTA-observing customer follows as an explicit mixture of Erlang distributions – exact raw moments and an exact tail $P(W > D)$, not just the mean, unlike the one directly comparable prior treatment of this system class. The result regresses exactly to the classical $M/M/k/N$ queue at an occupancy-independent rate and to $M/M/1/N$ at $k = 1$; it is confirmed against independent discrete-event simulation. Numerically, a simple approximation that ignores the occupancy dependence (using the rate measured at full occupancy as a constant) is shown to systematically overstate deadline-violation probability – by one to two orders of magnitude at moderate occupancy and by several orders of magnitude at a large concurrency cap k.

Key words: queueing theory, occupancy-dependent service, birth-death process, concurrency cap, continuous batching, large language model inference, KV-cache, exact waiting-time distribution.

Введение

Современные движки инференса больших языковых моделей (vLLM, SGLang и близкие по архитектуре) используют «непрерывный» (continuous, или поитерационный) батчинг: в отличие от классического пакетного обслуживания [1], где канал копит от a до b заявок и запускает обслуживание всего пакета разом [2], здесь состав одновременно обслуживаемых запросов меняется на каждой итерации декодирования – запрос присоединяется к уже исполняемой группе, как только освобождается место, и покидает её независимо от остальных. Число мест, которые могут быть заняты одновременно (k), задаётся не произвольным порогом, а объёмом доступной памяти ускорителя для KV-cache, а интенсивность обслуживания каждого запроса, как правило, зависит от текущей занятости: все резидентные запросы делят одну итерацию вычислений, и большая группа означает большую амортизацию, но и большую конкуренцию за пропускную способность памяти.

Такая occupancy-зависимая интенсивность обслуживания с потолком занятости структурно отличается от уже рассмотренного в [2] и в работах автора [3—5] атомарного пакетного обслуживания: здесь нет понятия «пакет», завершающегося целиком, а есть обычный процесс гибели-размножения по числу заявок в системе, но с зависящей от состояния интенсивностью смерти.

Системы массового обслуживания с occupancy-зависимой (state-dependent) интенсивностью обслуживания известны с 1970-х годов [6] и ранее – сама по себе такая цепь не нова. Точное распределение времени ожидания для неё, однако, найдено (насколько можно судить по проведённому обзору)

лишь для одно- и двухсерверного случаев с двухуровневой (пороговой) интенсивностью [6]. Специализированная монография по этой теме [7] (защищена под руководством одного из ведущих авторов данного направления) целиком ограничена односерверным случаем ($G/G/1$-постановки: зависимость от объёма работы, дамбы и накопители, оптимальный допуск, адаптируемая скорость обслуживания) – ни одна из её семи глав не рассматривает многоканальную систему с потолком одновременной занятости. Обобщение на произвольное число одновременно обслуживаемых заявок k и произвольный профиль интенсивности по occupancy в явном виде не найдено.

Современная литература по LLM-serving активно рассматривает ту же систему применительно к continuous batching, но ограничивается либо приближённым, либо неполным результатом. Yang, Xu и Jiao [8] формулируют M/G/1 и пакетную модель с учётом длины вывода, но получают только среднее время ожидания и не рассматривают occupancy-зависимую интенсивность с потолком занятости как таковую. Ramani и Tantawi [9] строят ту же «state-dependent Markov chain for batch occupancy», что и в настоящей работе, но решают её приближённо, методом среднего значения (mean-value analysis), и дают только среднее время до первого токена и средний межтокенный интервал (ошибка валидации против реальных замеров – 5–16 %). Nie, Si и Zhou [10] дают условия устойчивости/неустойчивости такой системы, но не стационарное распределение времени ожидания. Ao с соавторами [11] рассматривают смежный, но принципиально иной вопрос – детерминированную (не стохастическую) динамику перегрузки при вытеснении KV-cache, предельные циклы и потерю пропускной способности, другим математическим аппаратом (динамические системы, не цепи Маркова).

Таким образом, пересечение «точно»×«полное распределение (не только среднее)»×«произвольное k»×«произвольный профиль occupancy-зависимой интенсивности» не закрыто ни одной из найденных работ. Настоящая статья даёт такое точное решение, включая точный хвост $P(W > D)$, представляющий прямой практический интерес для SLA-ориентированного управления инференс-серверами.

Постановка задачи

Рассматривается система с пуассоновским входным потоком интенсивности λ, в которой одновременно может обслуживаться не более k заявок; интенсивность обслуживания каждой из них, пока занято ровно n мест ($1 \le n \le k$), равна $\mu(n)$ – общая, не обязательно постоянная зависимость от occupancy n (в частности, occupancy-независимая интенсивность – частный случай). Заявки, заставшие все k мест занятыми, ожидают по FCFS; как только освобождается место, его немедленно занимает первая заявка из очереди (если очередь не пуста).

Цель – точное распределение времени ожидания W PASTA-наблюдающей (случайно выбранной) заявки до момента её допуска в число одновременно обслуживаемых, при произвольном k и произвольной зависимости $\mu(n)$, $1 \le n \le k$.

Метод

Стационарное распределение числа в системе – известный результат (метод Эрланга). Пусть j – полное число заявок в системе (обслуживаемых и ожидающих), $0 \le j \le N$ (усечение по N для вычислений). Занятость в состоянии j равна $\min(j,k)$, поэтому суммарная интенсивность выхода из состояния j («интенсивность смерти») равна

$$\delta(j) = \min(j,k) \cdot \mu(\min(j,k)). \tag{1}$$

Цепь по j – процесс гибели-размножения с интенсивностью рождения λ и интенсивностью смерти $\delta(j)$. Для произвольного процесса гибели-размножения со сколь угодно зависящими от состояния интенсивностями стационарное распределение в замкнутой, не итеративной форме – классический результат, известный как метод Эрланга [12]:

$$\pi_j = \pi_0 \prod_{i=1}^{j} \frac{\lambda}{\delta(i)}, \qquad \pi_0 = \left(\sum_{j=0}^{N} \prod_{i=1}^{j} \frac{\lambda}{\delta(i)} \right)^{-1}. \tag{2}$$

Там же выписан частный случай n-линейной системы $M/M/n$, для которого при $j > n$ интенсивность смерти не зависит от j и равна $n\mu$ – тот же классический факт, на котором строится формула Эрланга-С, нужен нам в следующем пункте уже для произвольного (не обязательно постоянного ниже потолка) профиля $\mu(n)$.

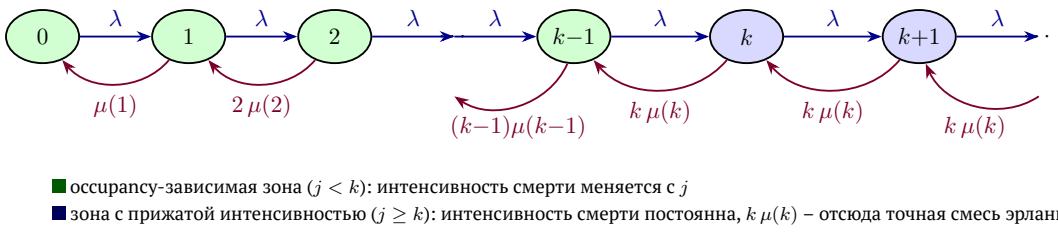
Интенсивность смерти выше потолка – тот же классический факт, перенесённый на произвольный профиль. Для всех $j \ge k$ занятость равна в точности k, поэтому из формулы (1) непосредственно $\delta(j) = k \cdot \mu(k)$ – не зависит от j, какой бы ни была зависимость $\mu(n)$ при $n < k$ (это следует из построения: пока очередь не пуста, любое освобождение места немедленно восполняется из очереди, поэтому занятость не может опуститься ниже k). Новое здесь – не сам этот факт (он тот же, что и в формуле Эрланга-С выше), а то, что он верен при произвольном профиле $\mu(n)$ ниже потолка, а не только при постоянном: ниже мы используем это, чтобы получить точное распределение времени ожидания, а не только стационарные вероятности состояний.

Время ожидания. По свойству PASTA заявка, приходящая в систему, видит стационарное распределение π_j. Если $j < k$ – заявка допускается немедленно, $W = 0$. Если $j \ge k$ – заявка становится $(j-k+1)$-й в очереди и должна дождаться ровно $(j-k+1)$ освобождений мест; эти освобождения происходят с постоянной интенсивностью $k \cdot \mu(k)$ независимо от того, что происходит ниже потолка – то есть условное (на $j \ge k$) время ожидания есть точный $\mathrm{Erlang}(j-k+1,\, k\cdot\mu(k))$, ровно как для тех же $(j-k+1)$ заявок впереди в классической системе $M/M/k$. Безусловные точные начальные моменты и точный хвост:

$$\mathrm{E}[W^n] = \sum_{j=k}^{N} \pi_j \, \frac{(j-k+1)(j-k+2)\cdots(j-k+n)}{(k\,\mu(k))^n}, \tag{3}$$

$$P(W > t) = \sum_{j=k}^{N} \pi_j \sum_{i=0}^{j-k} \frac{e^{-k\,\mu(k)\,t}\,(k\,\mu(k)\,t)^i}{i!}. \tag{4}$$

На рисунке 1 схематично показана цепь: состояния $j < k$ образуют occupancy-зависимую зону (интенсивность зависит от j), состояния $j \geq k$ – зону с постоянной, «прижатой» к потолку интенсивностью.



■ occupancy-зависимая зона ($j < k$): интенсивность смерти меняется с j
■ зона с прижатой интенсивностью ($j \geq k$): интенсивность смерти постоянна, $k\,\mu(k)$ – отсюда точная смесь эрлангов для W

Рисунок 1. Процесс гибели-размножения по числу заявок в системе j: при $j \geq k$ интенсивность смерти не зависит от j, поскольку занятость жёстко зафиксирована на потолке k

Регрессионные тождества. При $\mu(n) \equiv \text{const}$ для всех n результат должен точно совпасть с классической системой $M/M/k/N$; при $k = 1$ – с классической $M/M/1/N$ при любой зависимости (единственное occupancy-значение $n = 1$). Оба тождества подтверждены точно (таблица 1).

Третий, качественный (не численно проверяемый ввиду вырожденности предела) вырожденный случай – $k \to \infty$ с $\mu(n) = C/n$: занятость в этом пределе никогда не достигает потолка, $W \equiv 0$, и остаётся только разделение единой производительности C поровну между всеми находящимися в системе заявками – это ровно дисциплина egalitarian processor sharing (EPS) [13]; её перенос на n-канальный случай соответствующим пересчётом производительности изложен в [12]. Принципиальное отличие настоящей постановки от EPS – именно в невырожденном случае конечного k: EPS по построению не знает понятия отказа в немедленном допуске (мощность делится между сколь угодно большим числом заявок), поэтому у неё нет и не может быть содержательного понятия времени ожидания до начала обслуживания – вся соответствующая литература говорит о времени пребывания, не о времени ожидания в очереди. Конечный потолок занятости k и FCFS-очередь вне его – именно то структурное отличие, которое впервые делает время ожидания W ненулевым и нетривиальным для этого класса систем.

Таблица 1. Точная регрессия к классической $M/M/k/N$ при occupancy-независимой интенсивности

k	λ	μ	E[W] (данная модель)	E[W] ($M/M/k/N$)
4	3,0	1,00	0,509434	0,509434
8	6,0	1,00	0,178491	0,178491
16	10,0	0,80	0,094323	0,094323

Численные эксперименты

Проверка независимым имитационным моделированием. Для occupancy-зависимой интенсивности $\mu(n) = 1/(\tau_0 + \tau_1 n)$ (иллюстративные параметры $\tau_0 = 0{,}05$, $\tau_1 = 0{,}01$ – структура «базовый расход на итерацию + расход на занятое место», в духе параметризации [9], но не повторяющая её конкретные подогнанные значения) и потолка $k = 4$ точный расчёт сопоставлен с независимым (написанным с нуля, не переиспользующим библиотечный код) дискретно-событийным имитационным моделированием при трёх уровнях загрузки (таблица 2, 3×10^6 заявок на прогон).

Таблица 2. Расчёт и имитация ($k = 4$, occupancy-зависимая интенсивность, 3×10^6 заявок на прогон)

ρ	E$[W]$			$P(W > 0{,}05)$		
	теор.	ИМ	отн. ошибка	теор.	ИМ	отн. ошибка
0,3	0,00077	0,00078	0,58 %	0,00508	0,00514	1,06 %
0,5	0,00601	0,00605	0,64 %	0,04398	0,04421	0,52 %
0,7	0,02805	0,02824	0,68 %	0,19202	0,19279	0,40 %

Эффект игнорирования occupancy-зависимости. Естественное инженерное упрощение – измерить интенсивность при полной занятости $\mu(k)$ и использовать её как константу, то есть свести систему к классической $M/M/k/N$ с единственной интенсивностью $\mu(k)$ (приближение в духе [9], но не воспроизводящее их конкретный метод). Таблица 3 сравнивает точный результат с этим приближением при фиксированной относительной загрузке $\lambda = 0{,}6 \cdot k \cdot \mu(k)$ и растущем потолке k (та же occupancy-зависимая интенсивность, что выше).

Таблица 3. Точное E$[W]$ **против приближения по интенсивности полной занятости, при фиксированной относительной загрузке** $0{,}6$

k	E$[W]$ точное	E$[W]$ приближение	Во сколько раз больше	
			E$[W]$	$P(W > 1)$
4	0,01328	0,01615	1,22	1,22
8	0,00282	0,00567	2,01	2,01
16	0,00016	0,00137	8,84	11,3
32	4×10^{-7}	$1{,}5 \times 10^{-4}$	491	$9{,}5 \times 10^3$

Приближение систематически завышает время ожидания и вероятность нарушения дедлайна – оно приписывает всем состояниям медленную интенсивность полной занятости, тогда как при малой занятости (вдали от потолка) реальная интенсивность заметно выше. Расхождение растёт с k: при $k = 4$ приближение завышает умеренно (в 1,2 раза), при $k = 32$ – на три-четыре порядка. Это важно практически: чем больше памяти ускорителя отведено под KV-cache (то есть чем больше допустимый потолок занятости k), тем дороже обходится инженерное упрощение, игнорирующее occupancy-зависимость интенсивности.

Таблица 4. Точный хвост против приближения по интенсивности полной занятости, по сетке дедлайнов ($k = 16$, та же относительная загрузка $0{,}6$)

D	$P(W > D)$ точная	$P(W > D)$ приближение	Во сколько раз больше
0,02	$2{,}57 \times 10^{-3}$	$2{,}28 \times 10^{-2}$	8,84
0,05	$1{,}03 \times 10^{-3}$	$9{,}12 \times 10^{-3}$	8,84
0,10	$2{,}25 \times 10^{-4}$	$1{,}99 \times 10^{-3}$	8,84
0,20	$1{,}07 \times 10^{-5}$	$9{,}44 \times 10^{-5}$	8,84
0,40	$2{,}40 \times 10^{-8}$	$2{,}13 \times 10^{-7}$	8,84

При фиксированном k (в отличие от роста по k в таблице 3) кратность расхождения в этом примере практически не меняется по всей проверенной сетке дедлайнов – приближение искажает общую вероятностную массу хвоста систематически, а не его форму на этом участке.

Ограничения

Фиксированный, не зависящий от истории заявки объём ресурса на одно место (k – экзогенная константа): реальный KV-cache растёт по мере генерации токенов конкретным запросом, то есть фактический потолок одновременно допустимых запросов зависит от состава уже резидентных, а не только от их числа. Обобщение на растущий во времени ресурсный след – отдельное направление (ближайшая существующая структура в библиотеке most-queue – модели multiserver-job).

Остаточное время обслуживания предполагается экспоненциальным (марковским) при каждом уровне occupancy; реальная оставшаяся длина генерации, вообще говоря, не экспоненциальна. Перенос уже имеющегося в библиотеке аппарата фазового (Эрланга/H_2) обслуживания на occupancy-зависимую интенсивность – естественное расширение, не рассмотренное здесь.

Не рассмотрены: двухфазность обслуживания (отдельные по характеру фазы prefill и decode современных инференс-движков); нетерпение заявок; само время обслуживания после допуска в активный пул (величина W в данной работе – только задержка до допуска, не полное время пребывания в системе).

Численное сравнение с «приближением по интенсивности полной занятости» – собственная, явно обозначенная как иллюстративная конструкция автора, в духе общей структуры приближённого метода [9], но не повторяющая его конкретные подогнанные параметры и не являющаяся прямым воспроизведением чьих-либо опубликованных численных результатов.

Заключение

Получено и верифицировано точное распределение времени ожидания (начальные моменты и хвост) для occupancy-зависимой системы массового обслуживания с потолком занятости произвольной величины k и произвольным профилем зависимости интенсивности от занятости – марковской модели ядра continuous batching современных LLM-инференс-движков. Результат обобща-

ет точный одно-/двухсерверный результат Morrison (1989) на произвольное k и даёт, в отличие от единственной найденной близкой по постановке современной работы, точный (не приближённый методом среднего значения) результат, включая точный хвост, а не только среднее. Численно показано, что инженерное упрощение, игнорирующее occupancy-зависимость интенсивности, систематически завышает оценку риска нарушения дедлайна, причём расхождение растёт с ростом допустимого потолка занятости – на один-два порядка при умеренном k и на несколько порядков при большом. Открытая программная реализация доступна в библиотеке most-queue [14].

Список литературы

1. *Bailey N. T. J.* On queueing processes with bulk service // Journal of the Royal Statistical Society. Series B. — 1954. — Т. 16. — С. 80—87.
2. *Inoue Y.* Queueing analysis of GPU-based inference servers with dynamic batching: a closed-form characterization // Performance Evaluation. — 2021. — Т. 147.
3. *Хабаров Р. С.*, *Лохвицкий В. А.* Точная вероятность нарушения SLA в одноканальных системах пакетного обслуживания с пороговым запуском пакета: нетерпеливые заявки. — 2026. — рукопись в подготовке.
4. *Хабаров Р. С.* Точная вероятность нарушения SLA в многоканальных системах пакетного обслуживания с общей очередью: нетерпеливые заявки. — 2026. — рукопись в подготовке.
5. *Хабаров Р. С.* Точное распределение времени ожидания в occupancy-зависимой системе массового обслуживания с потолком занятости. — 2026. — рукопись в подготовке.
6. *Morrison J. A.* Sojourn and waiting times in a single-server system with state-dependent mean service rate // Queueing Systems. — 1989. — Т. 4. — С. 213—235. — DOI: 10.1007/BF02100267.
7. *Bekker R.* Queues with state-dependent rates : дис. ... канд. / Bekker René. — Technische Universiteit Eindhoven, 2005. — DOI: 10.6100/IR598926.
8. *Yang Y.*, *Xu Y.*, *Jiao L.* A Queueing Theoretic Perspective on Low-Latency LLM Inference with Variable Token Length // arXiv preprint. — 2024. — arXiv: 2407.05347.
9. *Ramani V.*, *Tantawi A. N.* An Approximate Queueing Model of LLM Inference Serving for SLO-Driven Autoscaling // arXiv preprint. — 2026. — arXiv: 2609.20957.
10. *Nie C.*, *Si N.*, *Zhou Z.* A Queueing-Theoretic Framework for Stability Analysis of LLM Inference with KV Cache Memory Constraints // International Conference on Machine Learning (ICML). — 2026. — arXiv: 2605.04595.

11. Service-Induced Congestion in Memory-Constrained LLM Serving / R. Ao [и др.] // arXiv preprint. — 2026. — arXiv: 2606.15555.
12. *Рыжиков Ю. И.* Численные методы теории очередей: учебное пособие. — СПб. : Лань, 2018. — С. 512.
13. *Yashkov S. F.* Processor-sharing queues: Some progress in analysis // Queueing Systems. — 1987. — Т. 2. — С. 1—17. — DOI: 10.1007/BF01182931.
14. *Хабаров Р. С.* most-queue: библиотека точных и приближённых методов теории очередей. — 2026. — URL: https://github.com/xabarov/most-queue (дата обр. 06.10.2026).